





CNN - DQN HYBRID AGENT

Modelo de percepção e tomada
de decisão aplicado ao jogo 2048

Luiza Carvalho, Théo Evangelista, Lázaro
Queiroz e Tarcísio Araújo

**ENTENDENDO COMO O
JOGO FUNCIONA...**




Como o jogo funciona?

- **Objetivo principal**
 - Chegar à peça com valor 2048.
- **Mecânica do jogo**
 - Tamanho do tabuleiro: 4x4
 - Direções de jogadas: ➡️⬇️⬅️⬆️
 - Peças de valores iguais se fundem.
- **Somatório dos pontos**
 - A pontuação do jogo cresce a cada fusão bem-sucedida, e os pontos ganhos são exatamente o valor da nova peça criada.



Simulando uma partida

movimentações possíveis: deslizar para cima, para baixo, para esquerda e para direita.





ENTENDENDO COMO O AGENTE FUNCIONA...



CNN

Convolutional Neural Network

O que é uma CNN?

- Rede neural convolucional.

Para que usar a CNN?

- Visualização do tabuleiro.

Aspectos principais

- Aplicação de filtros e camadas
 - Convolucionais
 - Lineares

```
def forward(self, x):  
    x = x.view(-1, 16, 4, 4)  
    x = torch.relu(self.bn1(self.conv1(x)))  
    x = torch.relu(self.bn2(self.conv2(x)))  
    x = torch.relu(self.conv3(x))  
    x = x.view(x.size(0), -1)  
    x = torch.relu(self.fc1(x))  
    x = torch.relu(self.fc2(x))  
    return self.fc3(x)
```



DQN

Deep-Q-Network

O que é uma DQN?


- Algoritmo de aprendizagem por reforço.

Para que usar a DQN?


- Tomada de decisão.

Aspectos principais

- Q-values;
- Ciclo de aprendizagem.



Arquitetura geral do projeto



Hiperparâmetros DQN

1 - Learning Rate ($\alpha = 0.0001$):

- Controla o tamanho do passo na atualização dos pesos da rede

2 - Gamma / Discount Factor ($\gamma = 0.99$):

- Controla o quanto o agente valoriza recompensas futuras

3 - Epsilon ($\epsilon = 9.0 \rightarrow 0.02$):

- Controla o equilíbrio entre Exploration e Exploitation

4 - Batch Size (128) and Replay Buffer (100k):

- Número de experiências usadas em cada atualização da rede e quantidade de jogadas guardadas

5 - Tau ($\tau = 0.01$):

- Controla a velocidade de atualização da target network



MCTS no jogo

Fase 1 ? Selection

- Desce na árvore usando UCB para escolher o caminho mais promissor
- $UCB = Q/N + C \times \sqrt{(\ln(P)/N)}$

Fase 2 ? Expansion




- Encontra uma ação ainda não testada

Fase 3 ? Evaluation

- Usa o DQN como heurística para avaliar o estado novo

Fase 4 ? Backup



- Propaga o valor de volta até à raiz da CNN




Estrutura de Treinamento dos Agentes

O treinamento foi realizado para cada agente!


- **DQN:**
 - 50.000 episódios
 - 36 horas de treinamento
- **DQN + MCTS:**
 - 1.400 episódios
 - 48 horas de treinamento
 - 30 simulações MCTS
 - 15 de Profundidade Para cada N




Métricas de treinamento DQN



Métricas de treinamento MCTS



2048 DQN+MCTS Training Metrics




Estrutura de teste dos agentes


- **Foram testados três agentes:**
 - Agente Random Move
 - Agente DQN
 - Agente DQN + MCTS
- **Todos os agentes jogaram 1.000 partidas após o treinamento.**
- **As métricas de desempenho foram então computadas, e a distribuição dos resultados foi obtida para análise.**



Distribuição do valor máximo obtido em cada jogo



Max Tile Distribution Comparison



Melhores partidas de cada agente

2048 — Random DQN DQN+MCTS							
Random				DQN			
Score: 1948				Score: 2188			
4	16			256	64	2	2
32	8			32	4	2	
4	256	2	2	4			
4	8			4			

DQN+MCTS			
Score: 1648			
128	64	16	8
64	32	8	2
16	8	4	2
8	4	2	

**OBRIGADO PELA
ATENÇÃO, PESSOAL!**

